



UNIVERSITAS INDONESIA

ANALISIS PRODUKTIVITAS DAN DISTRAKSI MAHASISWA

LAPORAN PROYEK AKHIR

MATA KULIAH DASAR ANALITIK DATA

DISUSUN OLEH KELOMPOK 7:

GRACE YUNIKE MARGARETHA SITORUS	2306267031
SAMIH BASSAM	2306250623
WILMAN SARAGIH SITIO	2306161776
REINATHAN EZKHIEL KURNIAWAN	2406397675

**FAKULTAS TEKNIK
PROGRAM STUDI TEKNIK KOMPUTER
UNIVERSITAS INDONESIA
DEPOK**

DAFTAR ISI

DAFTAR ISI.....	2
BAB 1.....	3
PENDAHULUAN.....	3
1.1 LATAR BELAKANG.....	3
1.2 TUJUAN PROYEK.....	4
1.3 PEMILIHAN TARGET VARIABLE.....	5
1.4 BATASAN.....	6
1.5 TUJUAN.....	7
BAB 2.....	8
EKSPLORASI DATA.....	8
2.1 DESKRIPSI DATASET.....	8
2.2 PEMBERSIHAN DATASET.....	10
2.3 ANALISIS DESKRIPTIF DAN EKSPLORATIF.....	14
BAB 3.....	19
PERSIAPAN DATA.....	19
3.1 FEATURE ENGINEERING.....	19
3.2 TRANSFORMASI DATA.....	20
3.3 SELEKSI FITUR.....	23
BAB 4.....	25
PEMODELAN DAN EVALUASI MACHINE LEARNING.....	25
4.1 SKENARIO PENGUJIAN DAN METRIK EVALUASI.....	25
4.2 EKSPERIMEN ALGORITMA.....	26
4.3 PERBANDINGAN KINERJA MODEL.....	27
4.4 ANALISIS KELEBIHAN DAN KELEMAHAN MODEL.....	28
4.5 VALIDASI LANJUTAN.....	30
BAB 5.....	32
KESIMPULAN DAN IMPLIKASI BISNIS.....	32
5.1 KESIMPULAN.....	32
5.2 REKOMENDASI AKSI.....	33
5.3 RENCANA IMPLEMENTASI.....	34

BAB 1

PENDAHULUAN

1.1 LATAR BELAKANG

Produktivitas mahasiswa merupakan salah satu faktor yang sangat penting dalam mendukung keberhasilan akademik di perguruan tinggi. Produktivitas tidak hanya berkaitan dengan hasil akhir seperti nilai atau indeks prestasi, tetapi juga berkaitan dengan kualitas proses belajar yang dijalani mahasiswa dari hari ke hari. Mahasiswa yang produktif umumnya mampu mengalokasikan waktu belajarnya dengan baik, mempertahankan fokus dalam jangka waktu yang cukup, menjaga kehadiran perkuliahan, serta menyelesaikan tugas akademik secara konsisten. Sebaliknya, mahasiswa yang kurang produktif cenderung mengalami kesulitan dalam mengelola waktu, mudah terdistraksi, menunda pekerjaan akademik, dan pada akhirnya mengalami penurunan performa belajar.

Dalam konteks pendidikan tinggi saat ini, tantangan produktivitas mahasiswa tidak lagi hanya berkaitan dengan motivasi belajar atau kemampuan akademik, tetapi juga sangat dipengaruhi oleh perubahan pola hidup dan lingkungan digital. Kehadiran ponsel pintar, media sosial, platform video seperti YouTube, dan permainan digital telah menjadi bagian dari keseharian mahasiswa. Teknologi tersebut pada dasarnya dapat memberikan manfaat, misalnya untuk komunikasi, akses materi, dan pembelajaran daring. Namun, intensitas penggunaan yang tinggi juga dapat menjadi sumber distraksi yang mengurangi waktu belajar efektif, menurunkan konsentrasi, serta mengganggu ritme belajar yang sehat.

Distraksi digital menjadi perhatian penting karena dampaknya sering tidak terlihat secara langsung. Seorang mahasiswa dapat terlihat aktif belajar dalam durasi yang cukup panjang, tetapi kualitas belajarnya mungkin menurun akibat terlalu sering beralih perhatian ke perangkat digital. Pola ini dapat menurunkan kedalaman pemahaman,

mengurangi retensi materi, dan membuat proses belajar menjadi kurang efisien. Selain itu, penggunaan perangkat digital yang tinggi juga sering berkaitan dengan berkurangnya waktu tidur, munculnya kelelahan mental, dan meningkatnya tingkat stres. Pada akhirnya, faktor-faktor tersebut dapat memengaruhi produktivitas mahasiswa secara menyeluruh.

Dari sudut pandang institusi pendidikan, memahami faktor-faktor yang mendorong maupun menghambat produktivitas mahasiswa merupakan hal yang sangat penting. Kampus tidak cukup hanya menilai performa mahasiswa melalui nilai akhir, tetapi juga perlu memahami pola perilaku yang mendasari performa tersebut. Dengan memahami hubungan antara kebiasaan belajar, pola hidup, kondisi psikologis, dan distraksi digital, kampus dapat merancang intervensi yang lebih tepat sasaran. Bentuk intervensi tersebut dapat berupa program konseling, pelatihan manajemen waktu, penguatan layanan kesejahteraan mahasiswa, edukasi mengenai pola tidur sehat, hingga penciptaan ruang belajar yang lebih kondusif.

Pendekatan berbasis data menjadi relevan dalam situasi ini karena memberikan dasar pengambilan keputusan yang lebih objektif. Dengan memanfaatkan data yang memuat informasi mengenai durasi belajar, durasi tidur, penggunaan perangkat digital, tingkat stres, fokus, dan variabel terkait lainnya, analisis dapat dilakukan secara lebih terukur. Selain itu, *machine learning* memungkinkan tidak hanya dilakukannya eksplorasi hubungan antar variabel, tetapi juga pembangunan model prediktif yang mampu memperkirakan tingkat produktivitas mahasiswa berdasarkan kondisi-kondisi tersebut. Oleh karena itu, proyek akhir ini disusun untuk menganalisis produktivitas mahasiswa secara komprehensif dengan menggunakan kerangka CRISP-DM, sehingga hasilnya dapat memberikan kontribusi akademik sekaligus manfaat praktis bagi institusi pendidikan.

1.2 TUJUAN PROYEK

Proyek ini memiliki dua jenis tujuan utama, yaitu tujuan bisnis dan tujuan teknis. Dari sisi bisnis, proyek ini bertujuan menghasilkan rekomendasi yang dapat ditindaklanjuti oleh pihak universitas dalam upaya meningkatkan produktivitas dan kesejahteraan mahasiswa. Hasil analisis diharapkan dapat membantu kampus dalam

mengidentifikasi faktor-faktor yang paling berpengaruh terhadap produktivitas, baik faktor yang bersifat mendukung maupun faktor yang bersifat menghambat. Dengan demikian, pihak kampus dapat menyusun kebijakan atau program intervensi yang lebih tepat sasaran, misalnya melalui edukasi manajemen waktu, pelatihan fokus belajar, penguatan layanan konseling, maupun kampanye pengendalian distraksi digital.

Dari sisi teknis, proyek ini bertujuan membangun model *machine learning* bertipe regresi untuk memprediksi `productivity_score` mahasiswa berdasarkan fitur-fitur yang tersedia pada dataset. Model yang dibangun diharapkan memiliki tingkat kesalahan prediksi yang rendah, khususnya berdasarkan metrik MAE, sekaligus memiliki performa yang baik pada metrik RMSE dan R-squared. Selain itu, proyek ini juga bertujuan menghasilkan model yang cukup interpretatif, sehingga hubungan antara fitur-fitur utama dan target dapat dijelaskan secara rasional kepada pembaca non-teknis. Dengan demikian, model yang dihasilkan tidak hanya akurat, tetapi juga berguna dalam mendukung pengambilan keputusan.

Secara lebih rinci, tujuan proyek ini dapat dirangkum sebagai berikut:

1. Memahami karakteristik dan kualitas dataset yang digunakan.
2. Mengidentifikasi faktor-faktor utama yang berkaitan dengan produktivitas mahasiswa.
3. Menyiapkan data yang bersih dan siap untuk pemodelan.
4. Membandingkan beberapa metode seleksi fitur untuk memperoleh subset fitur yang optimal.
5. Membangun dan mengevaluasi beberapa model regresi.
6. Memilih model terbaik dan menerjemahkan hasilnya menjadi rekomendasi praktis bagi kampus.

1.3 PEMILIHAN TARGET VARIABLE

Variabel target yang digunakan dalam proyek ini adalah `productivity_score`. Pemilihan target ini dilakukan secara sadar dan eksplisit karena variabel tersebut paling langsung merepresentasikan tingkat produktivitas mahasiswa yang menjadi fokus utama proyek. Dibandingkan variabel lain seperti `final_grade`, `productivity_score` lebih tepat

digunakan karena tidak hanya mencerminkan hasil akhir akademik, tetapi juga menggambarkan kualitas aktivitas belajar secara lebih menyeluruh.

Secara teknis, `productivity_score` merupakan variabel numerik kontinu, sehingga jenis permasalahan yang dihadapi termasuk ke dalam regresi. Pemilihan pendekatan regresi ini penting karena model dapat menghasilkan prediksi skor yang lebih rinci dibandingkan jika target diubah menjadi kategori-kategori tertentu. Selain itu, distribusi target pada dataset ini relatif seimbang dan tidak menunjukkan ketimpangan ekstrem, sehingga cukup mendukung kestabilan pemodelan.

Alasan lain yang memperkuat pemilihan target ini adalah karena `productivity_score` didukung oleh fitur-fitur prediktor yang relevan. Variabel seperti `study_hours_per_day`, `sleep_hours`, `phone_usage_hours`, `attendance_percentage`, `stress_level`, dan `focus_score` secara logis memiliki hubungan dengan produktivitas. Dengan ketersediaan fitur-fitur tersebut, model memiliki dasar yang cukup kuat untuk mempelajari pola hubungan yang bermakna. Oleh karena itu, `productivity_score` dapat dinilai sebagai target yang sesuai, relevan, dan layak digunakan dalam proyek akhir ini.

1.4 BATASAN

Dalam menyusun proyek ini, terdapat beberapa batasan dan asumsi yang perlu dijelaskan agar interpretasi hasil tetap proporsional. Pertama, dataset yang digunakan bersifat sintesis. Data tersebut disusun untuk menyerupai kondisi nyata, tetapi bukan berasal langsung dari observasi riil mahasiswa. Konsekuensinya adalah pola hubungan antar variabel cenderung lebih rapi dan lebih deterministik dibandingkan data dunia nyata yang biasanya memiliki *noise* lebih tinggi.

Kedua, analisis yang dilakukan berfokus pada hubungan *cross-sectional*, yaitu hubungan antar variabel pada satu kumpulan observasi, bukan hubungan yang melacak perubahan perilaku dari waktu ke waktu. Dengan demikian, proyek ini tidak dirancang untuk menarik kesimpulan kausal yang kuat seperti pada studi *time-series*. Hasil yang diperoleh lebih tepat dibaca sebagai pola hubungan dan kemampuan prediksi berdasarkan data yang tersedia.

Ketiga, proyek ini hanya menggunakan variabel yang tersedia pada dataset. Faktor-faktor lain yang mungkin memengaruhi produktivitas mahasiswa, seperti kondisi ekonomi keluarga, motivasi intrinsik, keterlibatan organisasi, lingkungan sosial, atau kualitas pengajaran, tidak tercakup dalam model. Hasil analisis harus dipahami sebagai representasi dari ruang lingkup data yang ada, bukan gambaran yang sepenuhnya lengkap mengenai seluruh determinan produktivitas mahasiswa.

Terakhir, model terbaik yang diperoleh dalam proyek ini sangat dipengaruhi oleh karakteristik dataset yang digunakan. Apabila model akan diterapkan pada data riil, maka perlu dilakukan validasi ulang, penyesuaian preprocessing, dan evaluasi generalisasi secara lebih lanjut. Penjelasan mengenai batasan dan asumsi ini penting agar laporan tetap jujur secara akademik dan tidak memberikan klaim yang berlebihan.

1.5 TUJUAN

1. Memahami karakteristik dan kualitas dataset secara menyeluruh, termasuk distribusi setiap variabel, keberadaan *missing values*, duplikasi, dan *outlier*, serta sifat data yang bersifat sintesis.
2. Mengidentifikasi faktor-faktor kunci yang berhubungan secara signifikan terhadap Productivity Score, melalui analisis korelasi, uji statistik Pearson, dan ANOVA.
3. Menyiapkan dataset yang bersih dan siap pakai melalui serangkaian tahapan *Data Preparation*: penanganan *missing values*, penanganan *outlier*, *feature engineering*, *feature encoding*, *scaling*, dan *feature extraction*.
4. Menentukan subset fitur terbaik menggunakan gabungan pendekatan *Feature Selection* (Filter & Embedded) serta *Feature Extraction* (PCA) agar data siap untuk tahap pemodelan prediktif.
5. Membangun dan mengevaluasi model prediktif untuk memprediksi performa akademik mahasiswa berdasarkan fitur-fitur terpilih.

BAB 2

EKSPLORASI DATA

2.1 DESKRIPSI DATASET

Dataset yang digunakan dalam proyek ini berasal dari Kaggle dengan nama ***Student Productivity & Distraction Dataset***. Dataset tersebut terdiri atas **20.000 baris** dan **18 kolom**, sehingga cukup besar untuk mendukung proses eksplorasi data maupun pemodelan *machine learning*. Jumlah data yang besar memberikan keuntungan dari sisi stabilitas statistik karena pola-pola hubungan yang muncul cenderung tidak terlalu dipengaruhi oleh variasi sampel yang kecil.

Secara umum, kolom-kolom dalam dataset dapat dikelompokkan ke dalam beberapa kategori. Pertama, terdapat variabel identitas yaitu `student_id`. Kedua, terdapat variabel demografis seperti `age` dan `gender`. Ketiga, terdapat variabel kebiasaan akademik seperti `study_hours_per_day`, `assignments_completed`, `attendance_percentage`, dan `final_grade`. Keempat, terdapat variabel gaya hidup seperti `sleep_hours`, `breaks_per_day`, `coffee_intake_mg`, dan `exercise_minutes`. Kelima, terdapat variabel psikologis seperti `stress_level` dan `focus_score`. Terakhir, terdapat variabel-variabel yang mewakili distraksi digital, yaitu `phone_usage_hours`, `social_media_hours`, `youtube_hours`, dan `gaming_hours`. Variabel target yang akan diprediksi adalah `productivity_score`.

Dari sisi tipe data, mayoritas kolom bertipe numerik, sedangkan `gender` merupakan variabel kategorikal. Komposisi ini sangat sesuai untuk proyek regresi, karena sebagian besar informasi sudah tersedia dalam bentuk yang dapat diproses langsung oleh metode statistik dan *machine learning* setelah melalui transformasi yang diperlukan.

No	Kolom	Deskripsi	Tipe Data	Peran
1	<code>student_id</code>	ID unik mahasiswa	int64	Identifier

2	age	Usia mahasiswa	int64	Demografis
3	gender	Jenis kelamin mahasiswa	object	Demografis
4	study_hours_per_day	Jam belajar per hari	float64	Kebiasaan akademik
5	sleep_hours	Jam tidur per hari	float64	Gaya hidup
6	phone_usage_hours	Jam penggunaan ponsel per hari	float64	Distraksi digital
7	social_media_hours	Jam penggunaan media sosial per hari	float64	Distraksi digital
8	youtube_hours	Jam menonton YouTube per hari	float64	Distraksi digital
9	gaming_hours	Jam bermain game per hari	float64	Distraksi digital
10	breaks_per_day	Jumlah jeda atau istirahat per hari	int64	Gaya hidup
11	coffee_intake_mg	Konsumsi kopi atau kafein harian	int64	Gaya hidup
12	exercise_minutes	Durasi olahraga per hari	int64	Gaya hidup
13	assignments_completed	Jumlah tugas yang diselesaikan	int64	Akademik
14	attendance_percentage	Persentase kehadiran	float64	Akademik

15	stress_level	Tingkat stres	int64	Psikologis
16	focus_score	Skor fokus	int64	Psikologis
17	final_grade	Nilai akhir akademik	float64	Performa akademik
18	productivity_score	Skor produktivitas mahasiswa	float64	Target regresi

Tabel 2.1. Deskripsi variabel dataset

2.2 PEMBERSIHAN DATASET

Tahap pembersihan data dilakukan untuk memastikan bahwa data yang digunakan dalam pemodelan memiliki kualitas yang baik. Dalam proyek ini, proses pembersihan data difokuskan pada pemeriksaan missing values, duplikasi data, dan penanganan outlier. Tujuan utama dari tahap ini adalah memastikan bahwa model dibangun di atas data yang konsisten dan tidak mengandung masalah yang dapat mengganggu interpretasi hasil.

Hasil pemeriksaan menunjukkan bahwa dataset ini tidak memiliki missing values. Setiap kolom terisi penuh dengan jumlah observasi yang lengkap. Selain itu, pengecekan terhadap placeholder tersembunyi seperti string kosong, "?", atau token lain yang sering mewakili nilai hilang juga tidak menemukan masalah berarti. Dari sisi kelengkapan, data dapat dikatakan bersih. Pemeriksaan duplikasi data juga menunjukkan bahwa tidak ada baris yang tercatat lebih dari satu kali. Dengan demikian, tidak diperlukan langkah penghapusan duplikat.

Walaupun dataset ini bersih dari sisi missing values dan duplikasi, proses pembersihan data tidak berhenti di situ. Tahap berikutnya adalah deteksi dan penanganan outlier. Pada proyek ini, outlier diperiksa menggunakan metode IQR (*Interquartile Range*). Metode ini dipilih karena lebih *robust* terhadap distribusi yang tidak sepenuhnya normal dan tidak terlalu dipengaruhi oleh nilai ekstrem saat menentukan batas kewajaran.

Berdasarkan hasil pemeriksaan, jumlah outlier pada dataset ini sangat minimal, dan hanya sebagian kecil muncul pada productivity_score.

Untuk menangani outlier, digunakan metode ***Winsorization (Clamp Transformation)***. Metode ini dipilih karena lebih masuk akal dibandingkan penghapusan baris. Dengan *winsorization*, nilai-nilai ekstrem disesuaikan ke batas atas atau batas bawah yang masih dianggap wajar tanpa menghilangkan observasi. Pendekatan ini memberikan beberapa keuntungan. Pertama, seluruh 20.000 data tetap dipertahankan. Kedua, distribusi data menjadi lebih stabil. Ketiga, risiko distorsi pada korelasi dan pemodelan akibat nilai yang terlalu ekstrem dapat dikurangi. Pemilihan metode ini juga sejalan dengan tujuan menjaga *statistical power* dari dataset yang besar.

Kolom atau Komponen	Jumlah
student_id	0
age	0
gender	0
study_hours_per_day	0
sleep_hours	0
phone_usage_hours	0
social_media_hours	0
youtube_hours	0
gaming_hours	0
breaks_per_day	0
coffee_intake_mg	0
exercise_minutes	0
assignments_completed	0
attendance_percentage	0
stress_level	0


focus_score	0
final_grade	0
productivity_score	0
Total missing values	0
Jumlah duplikasi	0

Tabel 2.2. Ringkasan hasil pemeriksaan *missing values* dan duplikasi

Variabel	Lower Bound	Upper Bound	Jumlah Outlier
age	11.00	35.00	0
study_hours_per_day	-4.21	14.75	0
sleep_hours	-0.54	13.62	0
phone_usage_hours	-5.20	17.69	0
social_media_hours	-3.96	11.93	0
youtube_hours	-3.00	8.97	0
gaming_hours	-3.01	8.99	0
breaks_per_day	-6.50	21.50	0
coffee_intake_mg	-247.00	745.00	0
exercise_minutes	-60.00	180.00	0
assignments_completed	-12.50	31.50	0
attendance_percentage	9.45	130.41	0
stress_level	-4.50	15.50	0

focus_score	-5.50	134.50	0
final_grade	10.64	130.16	0
productivity_score	4.08	96.41	18

Tabel 2.3. Ringkasan outlier per variabel




Gambar 2.1. *Boxplot* variabel numerik untuk deteksi outlier

2.3 ANALISIS DESKRIPTIF DAN EKSPLORATIF

Setelah data dipastikan bersih, tahap berikutnya adalah memahami pola distribusi dan hubungan antar variabel melalui analisis deskriptif dan eksploratif. Tahap ini sangat penting karena sesuai dengan rubrik penilaian, laporan tidak hanya harus menampilkan statistik dasar, tetapi juga harus menjelaskan *insight* yang diperoleh dari eksplorasi data.

Secara deskriptif, distribusi variabel numerik pada dataset cenderung relatif simetris dan cukup rapi. Hal ini konsisten dengan sifat dataset yang sintetis. *Histogram* menunjukkan bahwa mayoritas variabel tidak memiliki kemencengan distribusi yang sangat ekstrem. *Boxplot* juga memperlihatkan bahwa pencilan pada data sangat terbatas. Dari sudut pandang awal, kondisi ini mendukung pemodelan karena data tidak menunjukkan gejala ketidakteraturan yang terlalu berat.



Gambar 2.2. *Histogram* distribusi variabel numerik


Variabel	Mean	Std	Min	Q1	Median	Q3	Max
age	23.01	3.75	17.00	20.00	23.00	26.00	29.00
study_hours_per_day	5.25	2.74	0.50	2.90	5.25	7.64	10.00
sleep_hours	6.52	2.03	3.00	4.77	6.51	8.31	10.00
phone_usage_hours	6.25	3.31	0.50	3.38	6.24	9.10	12.00
social_media_hours	4.00	2.31	0.00	2.00	4.01	5.97	8.00
youtube_hours	2.99	1.73	0.00	1.49	2.98	4.48	6.00
gaming_hours	2.99	1.73	0.00	1.49	2.97	4.49	6.00
breaks_per_day	7.54	4.02	1.00	4.00	8.00	11.00	14.00
coffee_intake_mg	249.65	143.71	0.00	125.00	249.00	373.00	499.00

exercise_minutes	59.65	34.61	0.00	30.00	60.00	90.00	119.00
assignments_completed	9.49	5.80	0.00	4.00	9.00	15.00	19.00
attendance_percentage	69.95	17.40	40.00	54.81	69.99	85.05	100.00
stress_level	5.48	2.87	1.00	3.00	5.00	8.00	10.00
focus_score	64.44	20.18	30.00	47.00	65.00	82.00	99.00
final_grade	70.27	17.28	40.00	55.46	70.31	85.34	99.99
productivity_score	50.18	16.09	0.00	38.70	50.24	61.78	100.00

Tabel 2.4. Statistik deskriptif variabel numerik

Analisis korelasi kemudian dilakukan untuk melihat hubungan antar variabel, khususnya hubungan dengan productivity_score. Hasil korelasi menunjukkan bahwa study_hours_per_day memiliki hubungan positif paling kuat terhadap produktivitas, yaitu sekitar **+0,73**. Temuan ini menunjukkan bahwa semakin lama durasi belajar mahasiswa, semakin tinggi pula kecenderungan produktivitasnya. Selain itu, focus_score juga memiliki korelasi positif yang cukup kuat sekitar **+0,41**, yang menegaskan bahwa kualitas fokus berperan penting dalam mendukung produktivitas. Variabel sleep_hours

turut menunjukkan korelasi positif sekitar **+0,34**, sehingga kualitas istirahat juga dapat dianggap sebagai faktor yang membantu menjaga produktivitas.



Gambar 2.3. Heatmap correlation matrix

Fitur	Korelasi Pearson	Arah Hubungan
study_hours_per_day	0.732777	Positif
focus_score	0.411366	Positif
sleep_hours	0.340902	Positif
attendance_percentage	0.176107	Positif

coffee_intake_mg	0.010190	Positif
exercise_minutes	0.002892	Positif
final_grade	0.001954	Positif
social_media_hours	0.001285	Positif
gaming_hours	0.000685	Positif
youtube_hours	-0.000224	Negatif
assignments_completed	-0.001757	Negatif
age	-0.005423	Negatif
breaks_per_day	-0.005836	Negatif
stress_level	-0.197128	Negatif
phone_usage_hours	-0.326650	Negatif

Tabel 2.5. Korelasi fitur terhadap productivity_score

Di sisi lain, variabel yang paling jelas berperan sebagai penghambat adalah phone_usage_hours, dengan korelasi negatif sekitar **-0,33**. Angka ini menunjukkan bahwa semakin tinggi penggunaan ponsel, semakin rendah produktivitas mahasiswa. Variabel stress_level juga berkorelasi negatif sekitar **-0,20**, yang memperlihatkan bahwa peningkatan tingkat stres berhubungan dengan penurunan produktivitas. Temuan ini sangat penting karena mendukung argumen bahwa produktivitas mahasiswa tidak hanya dibentuk oleh kebiasaan belajar, tetapi juga oleh kondisi psikologis dan intensitas distraksi digital.

Insight dari *EDA* inilah yang kemudian menjadi dasar untuk tahap *feature engineering*, transformasi data, dan seleksi fitur. Dengan kata lain, *EDA* tidak hanya berfungsi sebagai tahap deskriptif, tetapi juga menjadi jembatan menuju keputusan teknis di tahap berikutnya.

BAB 3

PERSIAPAN DATA

3.1 FEATURE ENGINEERING

Setelah memahami pola dasar pada data, tahap berikutnya adalah memperkaya representasi informasi melalui *feature engineering*. *Feature engineering* dilakukan untuk menghasilkan fitur-fitur baru yang secara analitis lebih mampu menangkap perilaku mahasiswa dibandingkan hanya mengandalkan fitur mentah. Pada proyek ini, dibuat empat fitur turunan utama, yaitu `total_screen_time`, `study_sleep_ratio`, `stress_category`, dan `age_group`.

Fitur `total_screen_time` dibuat dengan menggabungkan durasi penggunaan ponsel, media sosial, YouTube, dan gaming. Tujuannya adalah membentuk satu indikator gabungan yang merepresentasikan total paparan distraksi digital. Secara bisnis, fitur ini penting karena pihak kampus sering kali tidak membutuhkan rincian terlalu teknis per platform, tetapi lebih membutuhkan gambaran menyeluruh mengenai intensitas distraksi layar yang dialami mahasiswa.

Fitur `study_sleep_ratio` dibuat untuk melihat keseimbangan antara jam belajar dan jam tidur. Rasio ini dipandang relevan karena produktivitas mahasiswa tidak hanya ditentukan oleh seberapa lama belajar, tetapi juga oleh seberapa baik dalam menjaga pemulihan fisik dan mental melalui tidur. Mahasiswa dengan jam belajar tinggi tetapi jam tidur terlalu rendah mungkin terlihat rajin, tetapi dalam jangka tertentu berpotensi mengalami kelelahan atau penurunan fokus.

Fitur `stress_category` dan `age_group` dibentuk melalui proses kategorisasi. Kedua fitur ini berguna untuk membantu analisis segmentasi. `stress_category` membantu mengelompokkan mahasiswa berdasarkan tingkat stres secara lebih mudah dipahami, sedangkan `age_group` membantu melihat apakah ada pola produktivitas yang berbeda antar kelompok usia. Walaupun pada model akhir fitur-fitur ini tidak semuanya terpilih,

proses pembentukannya tetap penting karena menunjukkan bahwa eksplorasi perilaku mahasiswa dilakukan secara komprehensif.

Tahap *feature engineering* pada proyek ini merupakan upaya untuk menggali representasi perilaku yang lebih informatif. Hal ini juga menjawab catatan penilaian bahwa apabila hasil model belum memadai, maka *derived features* perlu dicoba sebagai bagian dari optimisasi.

Fitur Turunan	Sumber atau Formula	Alasan Analitis dan Bisnis
total_screen_time	phone_usage_hours + social_media_hours + youtube_hours + gaming_hours	Menggambarkan total paparan layar sebagai satu indikator distraksi digital terpadu.
study_sleep_ratio	study_hours_per_day / sleep_hours	Mengukur keseimbangan antara usaha belajar dan waktu pemulihan melalui tidur.
stress_category_encoded	Kategorisasi stress_level menjadi rendah, sedang, tinggi	Mempermudah segmentasi tingkat stres dan interpretasi perilaku mahasiswa.
age_group_encoded	Kategorisasi age menjadi kelompok usia tertentu	Mempermudah segmentasi berdasarkan tahap usia mahasiswa.

Tabel 3.1. Daftar fitur turunan dan rasionalisasi pembentukannya

3.2 TRANSFORMASI DATA

Tahap transformasi data dilakukan agar seluruh fitur dapat diproses secara tepat oleh model *machine learning*. Transformasi yang diterapkan meliputi encoding variabel kategorikal, *train-test split*, serta *scaling* untuk fitur numerik tertentu.

Untuk variabel kategorikal, digunakan dua pendekatan encoding yang berbeda sesuai sifat datanya. Variabel gender ditransformasikan menggunakan ***One-Hot Encoding*** karena bersifat nominal dan tidak memiliki urutan alami. Sementara itu, *stress_category* dan *age_group* ditransformasikan menggunakan ***Ordinal Encoding*** karena kedua variabel tersebut memiliki tingkatan yang logis dan berurutan. Pemilihan metode encoding yang sesuai sangat penting agar model tidak menafsirkan urutan yang tidak seharusnya atau kehilangan informasi tingkatan yang memang penting.

Hal yang sangat penting pada tahap ini adalah urutan pemrosesan data. Proyek ini menerapkan ***train-test split 80:20*** sebelum ***StandardScaler***. Keputusan ini bukan sekadar prosedur teknis biasa, tetapi merupakan bagian penting dari pencegahan ***data leakage***. Apabila *scaling* dilakukan sebelum pemisahan data, maka informasi dari data uji akan ikut memengaruhi parameter *scaling* seperti rata-rata dan standar deviasi. Akibatnya, performa model pada data uji akan terlihat lebih baik daripada kondisi sebenarnya, karena model secara tidak langsung sudah menerima informasi dari data yang seharusnya belum dilihat.

Dengan melakukan *train-test split* terlebih dahulu, kemudian mempelajari parameter *scaling* hanya dari *training set*, evaluasi model menjadi lebih valid. Hal ini sangat relevan dengan catatan penilaian proyek yang menekankan pentingnya pembahasan pemilihan *training set* versus *test set* serta justifikasi prosedur evaluasi. Dalam proyek ini, setelah proses *feature engineering* dan encoding, total fitur model menjadi **21 fitur**, dan seluruh proses *scaling* diterapkan dengan tetap menjaga disiplin *anti-data leakage*.

Tahap	Detail Proses	Hasil
Data awal	Dataset mentah sebelum pembersihan dan transformasi	20.000 baris × 18 kolom
Drop identifier	student_id dihapus karena hanya berfungsi sebagai penanda unik	Menjadi 20.000 baris × 17 kolom
Feature engineering	Menambah total_screen_time, study_sleep_ratio, stress_category_encoded, age_group_encoded	Menjadi 20.000 baris × 21 kolom
One-Hot Encoding	gender diubah menjadi gender_Male dan gender_Other, dengan gender_Female sebagai kategori referensi	Shape setelah encoding: 20.000 baris × 22 kolom
Ordinal Encoding	stress_category dan age_group direpresentasikan sebagai nilai bertingkat	Tersimpan sebagai stress_category_encoded dan age_group_encoded
Fitur model (X)	Seluruh fitur setelah encoding, tanpa productivity_score	Total 21 fitur
Train-test split	Proporsi 80:20 dilakukan sebelum scaling	16.000 data training dan 4.000 data testing
StandardScaler	Diterapkan hanya pada fitur kontinu	13 fitur di-scale: study_hours_per_day, sleep_hours, phone_usage_hours, social_media_hours, youtube_hours, gaming_hours, coffee_intake_mg, exercise_minutes, attendance_percentage, focus_score, final_grade, total_screen_time, study_sleep_ratio
Fitur encoded	Fitur hasil one-hot dan ordinal encoding tidak di-scale	Menjaga makna kategorikal tetap konsisten

Tabel 3.2. Transformasi data

3.3 SELEKSI FITUR

Seleksi fitur merupakan salah satu bagian terpenting dalam proyek ini, karena secara langsung berkaitan dengan kriteria penilaian laporan. Tujuan dari seleksi fitur adalah menyederhanakan model, mengurangi *noise*, menghindari fitur yang tidak relevan, serta meningkatkan interpretabilitas hasil. Dalam proyek ini, dilakukan perbandingan antara tiga pendekatan seleksi fitur, yaitu ***Filter Method***, ***Embedded Method***, dan ***Wrapper Method***.

Pendekatan pertama adalah ***Filter Method***, yang dalam proyek ini menggunakan kombinasi ***Pearson Correlation*** dan ***ANOVA/F-test***. Pearson digunakan untuk melihat kekuatan hubungan linier setiap fitur terhadap target, sedangkan ANOVA/F-test membantu menilai signifikansi statistik fitur terhadap target. Pendekatan filter bersifat cepat dan *model-agnostic*, sehingga sangat berguna sebagai tahap penyaringan awal. Hasilnya menunjukkan bahwa terdapat **9 fitur** yang lolos sebagai kandidat penting.

Pendekatan kedua adalah ***Embedded Method***, yang menggunakan ***Lasso L1 Regularization***. Lasso dipilih karena memiliki keunggulan penting, yaitu mampu melakukan seleksi fitur secara langsung selama proses pelatihan model. Melalui penalti L1, fitur-fitur yang kontribusinya rendah dapat didorong memiliki koefisien nol, sehingga otomatis tersaring keluar dari model. Pada proyek ini, Lasso berhasil mereduksi **21 fitur** menjadi **6 fitur** utama, yaitu `study_hours_per_day`, `focus_score`, `sleep_hours`, `phone_usage_hours`, `attendance_percentage`, dan `stress_level`.

Pendekatan ketiga adalah ***Wrapper Method***, yang diimplementasikan melalui ***Recursive Feature Elimination (RFE)***. Berbeda dari *filter method*, RFE melakukan seleksi fitur berdasarkan dampak langsungnya terhadap performa model. Hasil RFE pada proyek ini juga menghasilkan **6 fitur**, dan secara performa sangat mendekati hasil Lasso.


Berdasarkan perbandingan performa, *embedded method* dan *wrapper method* sama-sama memberikan hasil terbaik, tetapi **Lasso dipilih sebagai metode seleksi fitur final**. Alasan pemilihan ini bukan hanya karena performanya tinggi, tetapi juga karena Lasso memberikan model yang lebih ringkas, lebih mudah dijelaskan, dan lebih kuat

dalam mengurangi multikolinearitas. Dengan kata lain, pemilihan Lasso bukan hanya keputusan berbasis angka, tetapi juga keputusan berbasis kualitas interpretasi model.

Secara keseluruhan, tahap seleksi fitur pada proyek ini berhasil menunjukkan dengan jelas jumlah fitur sebelum dan sesudah optimisasi. Sebelum seleksi terdapat **21 fitur**, setelah filter tersisa **9 fitur**, dan setelah embedded maupun wrapper masing-masing tersisa **6 fitur**. Informasi ini penting karena sesuai dengan catatan penilaian, laporan harus menyampaikan secara eksplisit jumlah fitur yang digunakan sebelum dan sesudah seleksi, sekaligus menjelaskan justifikasi mengapa prosedur tersebut dipilih.

Metode	Jumlah Fitur	MAE	RMSE	R-squared
Filter (Pearson + ANOVA)	9	2.598633	3.280990	0.958202
Embedded (Lasso)	6	0.006815	0.023728	0.999998
Wrapper (RFE)	6	0.006815	0.023728	0.999998

Tabel 3.3. Perbandingan metode feature selection



Gambar 3.1. Grafik perbandingan metode feature selection

BAB 4

PEMODELAN DAN EVALUASI MACHINE LEARNING

4.1 SKENARIO PENGUJIAN DAN METRIK EVALUASI

Tahap pemodelan dalam proyek ini dirancang dengan skenario evaluasi yang jelas agar hasil yang diperoleh dapat dipertanggungjawabkan. Evaluasi utama menggunakan ***hold-out validation 80:20***, yaitu 80 persen data untuk pelatihan dan 20 persen data untuk pengujian. Proporsi ini dipilih karena ukuran dataset cukup besar, sehingga *test set* dengan 4.000 observasi sudah cukup representatif untuk menilai kemampuan generalisasi model.

Selain *hold-out*, dilakukan juga ***10-Fold Cross-Validation*** pada model terbaik. Penggunaan *cross-validation* bertujuan memastikan bahwa performa model tidak semata-mata bergantung pada satu pembagian data tertentu. Dengan kata lain, pendekatan ini digunakan sebagai validasi tambahan agar hasil yang diperoleh lebih stabil dan tidak bersifat kebetulan. Sementara itu, metode *bootstrap* tidak digunakan sebagai evaluasi utama karena pada ukuran dataset sebesar ini, kombinasi *hold-out* dan *cross-validation* sudah cukup memadai, sementara biaya komputasi *bootstrap* relatif lebih tinggi tanpa memberikan nilai tambah yang terlalu besar.

Metrik evaluasi yang digunakan meliputi **MAE**, **RMSE**, dan **R-squared**. MAE dipilih karena paling mudah diinterpretasikan dalam satuan poin produktivitas. RMSE digunakan karena memberikan penalti yang lebih besar pada kesalahan prediksi ekstrem, sehingga berguna untuk memeriksa apakah model sesekali menghasilkan prediksi yang jauh meleset. R-squared digunakan untuk mengukur seberapa besar variasi target yang dapat dijelaskan oleh model. Sebagai pelengkap, proyek ini juga menghitung **SSE** untuk menunjukkan total akumulasi kuadrat error. Namun, fokus utama interpretasi tetap berada pada MAE, RMSE, dan R-squared, karena ketiga metrik tersebut paling relevan bagi pembaca.

4.2 EKSPERIMEN ALGORITMA

Untuk memastikan bahwa model terbaik dipilih melalui proses perbandingan yang adil, proyek ini menguji lima algoritma regresi yang berbeda, yaitu ***Linear Regression***, ***Support Vector Regressor (SVR)***, ***K-Nearest Neighbors Regressor (KNN)***, ***Decision Tree Regressor***, dan ***Random Forest Regressor***. Pemilihan kelima algoritma tersebut dilakukan agar ada variasi pendekatan, mulai dari model linear yang sederhana hingga model *non-linear* dan *ensemble* yang lebih kompleks.

Linear Regression digunakan sebagai *baseline* utama karena hasil *EDA* menunjukkan adanya hubungan linier yang cukup kuat antara beberapa fitur dengan target, terutama *study_hours_per_day*. *SVR* dipilih karena dikenal mampu menangani pola *non-linear* dengan baik. *KNN* dipilih sebagai representasi model berbasis kedekatan jarak, sementara *Decision Tree* dan *Random Forest* dipilih sebagai representasi pendekatan berbasis aturan dan *ensemble*. Dengan variasi model tersebut, proses evaluasi menjadi lebih kaya karena dapat menunjukkan apakah kompleksitas model benar-benar memberikan manfaat tambahan.

Dalam eksperimen ini, dilakukan pula ***hyperparameter tuning*** pada model-model tertentu. *KNN* dituning menggunakan *GridSearchCV* untuk mencari kombinasi jumlah tetangga, jenis bobot, dan metrik jarak yang paling optimal. Selain itu, keluarga model linear juga dibandingkan lebih lanjut melalui ***Ridge***, ***Lasso***, dan ***ElasticNet*** untuk melihat apakah regularisasi dapat meningkatkan performa dibanding *Linear Regression* biasa. Keputusan untuk melakukan tuning ini penting agar perbandingan antar model tidak hanya berdasarkan parameter *default*, tetapi berdasarkan konfigurasi yang lebih optimal.

Algoritma	Karakteristik	Alasan Diuji
Linear Regression	Model linear, sederhana, sangat interpretatif	Digunakan sebagai baseline utama karena hasil EDA menunjukkan hubungan linear yang kuat dengan target.
SVR (RBF)	Model non-linear berbasis kernel	Diuji untuk melihat apakah fleksibilitas non-linear memberi

		peningkatan performa.
KNN Regressor	Model berbasis kedekatan jarak	Diuji sebagai pembanding non-parametrik yang sensitif terhadap struktur jarak dan scaling.
Decision Tree Regressor	Model berbasis aturan dan percabangan	Diuji karena mampu menangkap interaksi non-linear dan mudah diinterpretasikan secara struktur keputusan.
Random Forest Regressor	Ensemble dari banyak decision tree	Diuji untuk melihat apakah pendekatan ensemble dapat meningkatkan akurasi dan stabilitas.

Tabel 4.1. Daftar algoritma yang diuji dan alasan pemilihannya

4.3 PERBANDINGAN KINERJA MODEL


Hasil evaluasi pada data uji menunjukkan bahwa ***Linear Regression*** memberikan performa terbaik di antara lima model yang diuji. Nilai performa masing-masing model adalah sebagai berikut. *Linear Regression* menghasilkan **MAE 0,006815**, **RMSE 0,023728**, dan **R-squared 0,999998**. *SVR* menghasilkan **MAE 0,364471**, **RMSE 0,565068**, dan **R-squared 0,998760**. *Random Forest* menghasilkan **MAE 1,682264**, **RMSE 2,141120**, dan **R-squared 0,982200**. *KNN* menghasilkan **MAE 1,939093**, **RMSE 2,478620**, dan **R-squared 0,976146**. Sementara itu, *Decision Tree* memberikan performa terendah dengan **MAE 3,462711**, **RMSE 4,366821**, dan **R-squared 0,925958**.

Dari hasil tersebut terlihat jelas bahwa perbandingan performa model tidak cukup dijelaskan dengan istilah kualitatif seperti "lebih baik" atau "lebih rendah". Oleh karena itu, laporan ini menampilkan seluruh nilai metrik secara numerik agar dapat melakukan perbandingan secara objektif. Hal ini juga secara langsung menjawab catatan penilaian proyek yang menegaskan bahwa perbandingan performa model harus ditampilkan dalam bentuk angka, bukan sekadar deskripsi umum.

Secara khusus, hasil ini menunjukkan bahwa *Linear Regression* tidak hanya unggul tipis, tetapi unggul secara konsisten pada seluruh metrik utama. Keunggulan tersebut kemudian didukung lagi oleh nilai SSE yang jauh lebih kecil dibanding model-model lain. Temuan ini memperlihatkan bahwa untuk dataset ini, model yang sederhana justru paling cocok.

Model	MAE	RMSE	R-squared	SSE
Linear Regression	0.006815	0.023728	0.999998	2.252061
SVR (RBF)	0.364471	0.565068	0.998760	1277.206263
Random Forest	1.682264	2.141120	0.982200	18337.581260
KNN Regressor	1.939093	2.478620	0.976146	24574.226980
Decision Tree	3.462711	4.366821	0.925958	76276.491806

Tabel 4.2. Perbandingan performa lima model regresi



Gambar 4.1. Grafik perbandingan performa model

4.4 ANALISIS KELEBIHAN DAN KELEMAHAN MODEL

Salah satu temuan yang paling menarik dari proyek ini adalah bahwa *Linear Regression* justru mengungguli model-model yang lebih kompleks seperti *Random Forest* dan *SVR*. Secara konseptual, hal ini dapat dijelaskan oleh sifat dataset yang digunakan. Dataset bersifat sintesis dan hubungan antar variabelnya relatif rapi, pola

utama yang ingin dipelajari model cenderung bersifat linier. Dalam kondisi seperti ini, model linear yang sederhana dan stabil justru memiliki keuntungan, karena tidak perlu mengeluarkan kompleksitas tambahan untuk menangkap pola *non-linear* yang pada dasarnya tidak terlalu dominan.

SVR sebenarnya menunjukkan performa yang sangat baik, tetapi tetap sedikit tertinggal dari *Linear Regression*. Hal ini mengindikasikan bahwa fleksibilitas *non-linear* yang dimiliki *SVR* tidak memberikan keuntungan berarti pada data yang sudah dapat dijelaskan sangat baik oleh hubungan linier. *Random Forest* juga memperlihatkan performa yang cukup tinggi, tetapi tetap kalah karena kompleksitas *ensemble* yang dibawanya tidak menghasilkan peningkatan performa yang signifikan. *KNN* cenderung lebih sensitif terhadap struktur jarak dan *scaling*, sementara *Decision Tree* menjadi model dengan performa paling rendah karena lebih rentan terhadap *overfitting* pada struktur data seperti ini.

Perbandingan di dalam keluarga model linear juga menunjukkan bahwa regularisasi tidak memberikan peningkatan performa. *Ridge*, *Lasso*, dan *ElasticNet* semuanya sedikit tertinggal dari *Linear Regression* biasa. Hal ini menunjukkan bahwa setelah tahap seleksi fitur dilakukan, model dasar sudah sangat stabil, sehingga penalti tambahan pada koefisien justru sedikit menurunkan fleksibilitas model. Dengan demikian, *Linear Regression* tidak hanya menjadi model terbaik secara angka, tetapi juga model yang paling efisien dan paling mudah dijelaskan.

Model	Train MAE	Test MAE	Test R-squared
LinearRegression	0.008457	0.006815	0.999998
Ridge	0.009131	0.007483	0.999998
Lasso	0.026030	0.024444	0.999995
ElasticNet	0.079673	0.077812	0.999964

Tabel 4.3. Perbandingan keluarga model linear

4.5 VALIDASI LANJUTAN


Untuk memperkuat kesimpulan bahwa *Linear Regression* memang merupakan model terbaik, dilakukan validasi tambahan berupa **10-Fold Cross-Validation** dan **Residual Analysis**. Hasil *cross-validation* menunjukkan bahwa model memiliki **R-squared mean 0,999974 +/- 0,000022** dan **MAE mean 0,008469 +/- 0,001426**. Nilai rata-rata yang sangat tinggi dan standar deviasi yang sangat kecil menunjukkan bahwa model sangat stabil pada berbagai partisi data. Dengan kata lain, performa model tidak hanya bagus pada satu pembagian data uji, tetapi juga konsisten pada berbagai pembagian data.

Residual analysis dilakukan untuk memeriksa pola kesalahan model. Scatter plot residual terhadap nilai prediksi menunjukkan bahwa residual tidak membentuk pola sistematis yang jelas. Sebaran residual relatif acak dan memiliki varians yang cukup stabil di berbagai rentang prediksi. Hal ini mendukung asumsi **homoscedasticity**, yaitu bahwa varians error tidak berubah secara drastis pada nilai prediksi yang berbeda.


Selain itu, histogram residual menunjukkan bahwa error terpusat di sekitar nol dan cukup simetris. Ini mendukung asumsi bahwa distribusi error cenderung normal atau mendekati normal. Kedua hasil tersebut membuat model *Linear Regression* tampak lebih meyakinkan, karena tidak hanya memiliki metrik evaluasi yang sangat baik, tetapi juga menunjukkan perilaku residual yang baik. Inilah yang membuat isi menjadi lebih kuat dari sudut pandang metodologis dan memberikan informasi bahwa evaluasi model dilakukan secara mendalam, bukan berhenti pada angka MAE, RMSE, dan R-squared.

Metrik	Jumlah Fold	Mean	Std Dev	Nilai Minimum	Nilai Maksimum
R-squared	10	0.999974	0.000022	0.999937	1.000000
MAE	10	0.008469	0.001426	0.006721	0.011540

Tabel 4.3. Perbandingan keluarga model linear



Gambar 4.2. Scatter plot residual vs predicted



Gambar 4.3. Histogram residual

BAB 5

KESIMPULAN DAN IMPLIKASI BISNIS

5.1 KESIMPULAN


Berdasarkan seluruh tahapan analisis, proyek ini berhasil menunjukkan bahwa pendekatan analitik data dan *machine learning* dapat digunakan untuk memahami produktivitas mahasiswa secara sistematis. Mulai dari tahap *business understanding*, *data understanding*, *data preparation*, *modeling*, *evaluation*, hingga *deployment*, seluruh proses disusun mengikuti kerangka CRISP-DM agar alur pengerjaan tetap jelas dan dapat dipertanggungjawabkan.

Dari sisi teknis, hasil analisis menunjukkan bahwa *productivity_score* dapat dijelaskan dengan sangat baik oleh kombinasi fitur-fitur utama yang mewakili kebiasaan belajar, kondisi psikologis, kualitas istirahat, disiplin akademik, dan distraksi digital. Setelah melalui proses seleksi fitur, model akhir menggunakan enam fitur utama, yaitu *study_hours_per_day*, *focus_score*, *sleep_hours*, *phone_usage_hours*, *attendance_percentage*, dan *stress_level*. Model terbaik yang diperoleh adalah ***Linear Regression***, dengan performa **MAE 0,006815**, **RMSE 0,023728**, dan **R-squared 0,999998** pada data uji.

Dari sisi interpretasi model, fitur-fitur yang berdampak positif terhadap produktivitas adalah *study_hours_per_day*, *focus_score*, *sleep_hours*, dan *attendance_percentage*. Sementara itu, *phone_usage_hours* dan *stress_level* berdampak negatif terhadap produktivitas. Dengan demikian, hasil analisis ini menegaskan bahwa produktivitas mahasiswa pada dataset ini sangat dipengaruhi oleh keseimbangan antara perilaku belajar yang baik dan minimnya hambatan berupa distraksi digital maupun tekanan psikologis.

Komponen	Nilai	Arah Pengaruh
Intercept	56.0538	Konstanta model
study_hours_per_day	11.8396	Positif
focus_score	6.5446	Positif
sleep_hours	5.4833	Positif
attendance_percentage	2.8158	Positif
stress_level	-1.0781	Negatif
phone_usage_hours	-5.3478	Negatif

Tabel 5.1. Koefisien fitur model terbaik



Gambar 5.1. Visualisasi koefisien model *Linear Regression*

5.2 REKOMENDASI AKSI

Hasil analisis dalam proyek ini tidak berhenti pada pemilihan model terbaik, tetapi juga harus diterjemahkan ke dalam rekomendasi yang dapat dipertimbangkan oleh

pihak kampus. Rekomendasi pertama berkaitan dengan **fokus dan jam belajar**. Untuk `study_hours_per_day` dan `focus_score` merupakan dua faktor dengan pengaruh positif paling kuat, kampus dapat mempertimbangkan penyediaan ruang belajar khusus yang minim distraksi, seperti *Dedicated Focus Room*. Selain itu, kampus juga dapat mengadakan lokakarya teknik belajar seperti metode Pomodoro atau *deep work* untuk membantu mahasiswa meningkatkan kualitas fokus belajarnya.

Rekomendasi kedua berkaitan dengan **tidur dan stres**, `sleep_hours` terbukti berpengaruh positif dan `stress_level` berpengaruh negatif, kampus dapat mengembangkan program edukasi *sleep hygiene* dan memperkuat layanan konseling manajemen stres. Program semacam ini penting karena hasil model menunjukkan bahwa produktivitas mahasiswa tidak hanya dipengaruhi oleh aspek akademik, tetapi juga oleh kemampuan mahasiswa menjaga keseimbangan fisik dan psikologis.

Rekomendasi ketiga berkaitan dengan **pengendalian distraksi digital** yakni `phone_usage_hours` merupakan salah satu penghambat utama produktivitas, kampus dapat menjalankan kampanye *digital detox* atau edukasi penggunaan gawai yang lebih sehat. Kampus juga dapat mempertimbangkan pengaturan area belajar dengan distraksi digital minimum atau pembatasan akses hiburan non-akademik pada jaringan tertentu di lingkungan pembelajaran.

5.3 RENCANA IMPLEMENTASI

Sebagai tahap akhir, model yang telah dipilih tidak hanya disimpan sebagai hasil eksperimen, tetapi juga dipersiapkan untuk digunakan lebih lanjut melalui proses *deployment* sederhana. Dalam proyek ini, komponen *pipeline* seperti *scaler*, daftar fitur terpilih, dan model *Linear Regression* final telah diserialisasi menggunakan `joblib`. Selanjutnya, komponen tersebut diintegrasikan ke dalam aplikasi berbasis web menggunakan **Streamlit**.

Melalui aplikasi ini, pengguna seperti konselor kampus atau dosen wali dapat memasukkan data mahasiswa berdasarkan enam fitur utama yang digunakan model.

Sistem kemudian akan memproses data tersebut dengan *pipeline* yang sama seperti pada tahap *training* dan menghasilkan prediksi `productivity_score`. Prediksi tersebut dapat digunakan sebagai alat bantu untuk melakukan diskusi, simulasi, atau pemetaan awal terhadap kondisi produktivitas mahasiswa.

Agar implementasi model tetap relevan apabila digunakan lebih lanjut, perlu dilakukan *monitoring* terhadap beberapa hal. Pertama, kampus perlu memeriksa apakah distribusi data baru masih serupa dengan data yang digunakan untuk melatih model. Kedua, kampus perlu menilai apakah error prediksi model tetap kecil pada data nyata. Ketiga, apabila konteks mahasiswa berubah secara signifikan, maka model mungkin perlu dilatih ulang. Dengan demikian, *deployment* dalam proyek ini dipahami bukan sebagai tahap akhir yang statis, tetapi sebagai awal dari pemanfaatan model secara lebih aplikatif dan berkelanjutan.